統計分析結果的報導方式

Chen-Pan Liao

December 3, 2019



本文件全文之著作權屬廖鎮磐 (Chen-Pan Liao) 所有 (聲明日: December 3, 2019), 並採用姓名標示-相同方式分享 4.0 國際 (CC BY-SA 4.0; 詳細內容請見 http://creativecommons.org/licenses/by-sa/4.0/deed.zh_TW)。本文原始碼請見 https://github.com/chenpanliao/report-statistical-results-TC。

目錄

- 1. 前言 2
- 2. 單樣本均值檢驗 3
 - 2.1. 常態情況, 3 2.2. 非常態情況, 3
- 3. 配對兩樣本均值檢驗 4
 - 3.1. 常態情況, 4 3.2. 非常態情況, 5
- 4. 獨立兩樣本均值檢驗 6
 - 4.1. 常態情況, 6 4.2. 非常態情況, 7
- 5. 多樣本單因子均值檢驗 8
 - 5.1. 常態且變方同質情況, 8 5.2. 常態且變方異質情況, 9 5.3. 非常態情況, 10

- 6. 多樣本雙因子均值檢驗 11
- 7. 簡單線性迴歸 11
- 8. 簡單相關 13
 - 8.1. 雙常態分布情況, 13 8.2. 次序相關, 14
- 9. 卡方適合度檢驗 14
- 10. 卡方獨立性檢驗 15
- A. R code 17

1 前言

一般而言,在收隻樣本後必須報導描述性統計,包括中央趨勢 (如平均值或中位數)、樣本數及變異程度 (如標準偏差或標準誤差);這些敘述性統計若內容太多可以改以圖或表的方式呈現。對於特別感到興趣的參數應計算其信賴區間。進行檢驗後應報導檢定統計量 (如t、f、 χ^2 等)、自由度與 p-value,並報導合適的效果量 (如 Cohen d、r、 R^2 等)。在撰寫統計結果時,必須報導上述重要的統計結果,重新編排成有意義的圖或表,最終正確解讀結果。然而,在筆者經驗中,初學統計的大學生往往不能掌握這一連串撰寫統計結果的技巧。

因此,我收集了一些常見統計例題,並以學術報告口吻示範如何報導上述統計結果供學生模仿。以下我將按不同的分析情況示範報導分析結果,包括結果的文字撰寫與製作合適的圖表。因課程訓練需求,我刻意報導較多細節而看來十分繁瑣冗長。學生可以先模仿我的內容以撰寫統計學報告與作業,但未來其它課程或學術報告時應有所取捨。最末一併附上計算及繪圖之 R code。本文內容將隨課程進度持續增加內容。

本文關於效果量在筆者主持之課堂中並未多加說明,且不同的效果量適 合不同的統計方法,學生可按自己的能力決定是否報導效果量。

2 單樣本均值檢驗

2.1 常態情況

檢驗 8.8, 10.3, 11.1, 7.7, 10.4, 10.5, 9.4, 9.5, 9.4, 9.1 之中央趨勢是否顯著不同於 9。

結果指出,樣本平均 \pm 標準差為 9.62 ± 0.987 (n=10)。由 Shapiro-Wilk test 檢驗常態性發現不能拒絕常態之虚無假設 $(W=0.960,\ p=0.790)$,故以 one-sample two-tailed Student-t test 進行檢驗 $H_0:\mu=9$ 。結果指出,平均值的 95% 信賴區間為 [8.914,10.236],無法拒絕 $\mu=9$ 的虚無假說 $(t=1.986,\ DF=9,\ p=0.078)$ 。此外,Cohen D=0.627 顯示中度效果量。結論是,母體平均不顯著不等於 9,但由中度效果量推測,不顯著可能是因樣本數不足造成的。

2.2 非常態情況

檢驗 2.5, 0.25, 0.01, 1.74, 0.39, 0.09, 0.82, 0.2, 0.84, 0.76 之中央趨勢是否顯著不同於 2。

結果指出,樣本平均 \pm 標準差為 0.76 ± 0.797 (n=10)。由 Shapiro-Wilk test 檢驗常態性發現拒絕常態之虚無假設 (W=0.841, p=0.045),故以 Wilcoxon signed rank sum test 進行檢驗 H_0 :中位數 = 2。結果指出,應拒 絕中位數 = 2 的虚無假說 (樣本中位數 = 0.575, V=2, p=0.006)。此外,多達 90% 的樣本小於 2,顯示高度的效果量。結論是,母體中位數顯著不等於 2 且小於 2。 ¹

¹ 在雙尾檢驗後若顯著可以藉樣本平均或中位數的大小直接解釋為顯著大於或小於。

3 配對兩樣本均值檢驗

3.1 常態情況

檢驗以下配對樣本

$$x_1$$
 8.8 10.3 11.1 7.7 10.4 10.5 9.4 9.5 x_2 9.2 10.4 11.6 7.7 10.6 11.6 11.4 10.4

之差值 $(x_1 - x_2)$ 中央趨勢是否顯著小於 0.1。

結果指出, x_1 與 x_2 之平均 \pm 標準差分別為 9.71 ± 1.095 及 10.36 ± 1.344 ($n_{\text{pair}} = 8$; 圖 1a)。差值平均 \pm 標準差為 -0.65 ± 0.665 (圖 1b)。由 Shapiro-Wilk test 檢驗差值之常態性發現不能拒絕常態之虚無假設 (W = 0.883, p = 0.202),故以 two-sample paired t-test 檢驗 $H_0: \mu_1 - \mu_2 \geq 0.1$ 。結果指出,應拒絕虛無假設 (t = -3.188, DF = 7, p = 0.015)。此外,差值平均之 95% 信賴區間為 [-1.206, -0.0936],且 Cohen D = 1.728 顯示高度效果量。結論是:差值平均顯著小於 0 且差距之效果量甚高。

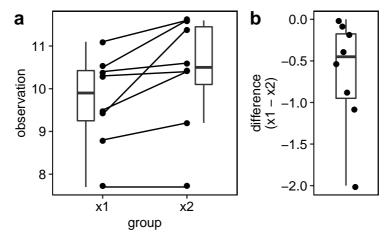


圖 1: 配對兩樣本的觀測值盒形圖 (a) 及差值盒形圖 (b)。

3.2 非常態情況

檢驗以下配對樣本

$$x_1$$
 5.1 6.9 7.2 6.5 7.2 6.4 5.3 7.7 x_2 5.6 6.2 6.6 6.7 6.7 5.8 4.8 8.1

之差值 $(x_1 - x_2)$ 中央趨勢是否顯著偏離 1。

結果指出, x_1 與 x_2 之平均 ± 標準差分別為 6.538 ± 0.924 及 6.313 ± 0.975 ($n_{\text{pair}} = 8$; 圖 2a)。 差值平均 ± 標準差為 0.225 ± 0.501 (圖 2b)。由 Shapiro-Wilk test 檢驗差值之常態性,結果顯示應拒絕常態之虚無假設 (W = 0.797, p = 0.026),故以 Wilcoxon signed rank sum test 進行檢驗 H_0 : 差值中位數 = 1。 結果顯示,差值中位數顯著不等於 1 (V = 0, p = 0.014) 而是小於 1。此外,100% 的樣本差值小於 1,具極高的效果量。結論是,差值母體中位數顯著小於 1 且效果量高。

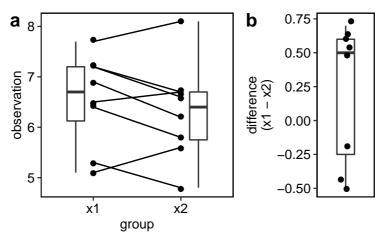


圖 2: 配對兩樣本的觀測值盒形圖 (a) 及差值盒形圖 (b)。

4 獨立兩樣本均值檢驗

4.1 常態情況

檢驗以下兩獨立樣本

$$x_1$$
 8.6 10 9.2 10.2 11.4 10.7 x_2 9.7 8.8 9.2 10.2 9.3 7.6 8.6

之中央趨勢是否顯著偏離 0。

結果指出, x_1 與 x_2 之平均 \pm 標準差分別為 10.02 ± 1.095 及 9.057 ± 0.836 ($n_1=6,\ n_2=7$; 圖 3)。由 Shapiro-Wilk test 檢驗差值之常態性發現二樣本皆不能拒絕常態之虚無假設 ($x_1,\ W=0.985,\ p=0.975$; $x_2,\ W=0.976,\ p=0.938$),故以 Welch two-Sample t-test 檢驗 $H_0:\mu_1-\mu_2=0$ 。結果指出不應拒絕虛無假設 ($t=1.848,\ DF=9.794,\ p=0.095$)。此外,差值平均之95% 信賴區間為 [-0.201,2.120],且 Cohen D=1.044 顯示高度效果量。結論是二樣本平均無顯著差異,但效果量甚高,可能因樣本數不足而發生型二錯誤。

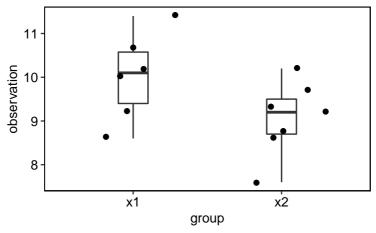


圖 3: 獨立兩樣本的觀測值盒形圖。

4.2 非常態情況

檢驗以下兩獨立樣本

$$x_1$$
 0 0.1 0.7 0.7 0.9 0.7 0 0.9 x_2 0.7 1.6 0.6 0.4 1.7 0.2 1.4

之中央趨勢是否顯著偏離 0。

結果指出, x_1 與 x_2 之平均 \pm 標準差分別為 0.5 ± 0.396 及 0.943 ± 0.611 ($n_1 = 8$; $n_2 = 7$; 圖 4)。由 Shapiro-Wilk test 檢驗差值之常態性發現 x_1 拒絕常態之虚無假設 (x_1 , W = 0.794, p = 0.024; x_2 , W = 0.890, p = 0.276),故以 Mann-Whitney U test 檢驗 H_0 : Median $_1$ — Median $_2$ = 0。結果指出不應拒絕虛無假設 (W = 18.5, p = 0.292)。此外,Cliff's d = 0.339 顯示中等程度效果量。結論是,二樣本之中位數無顯著差異,但效果量程中度,可能因樣本數不足而發生型二錯誤。

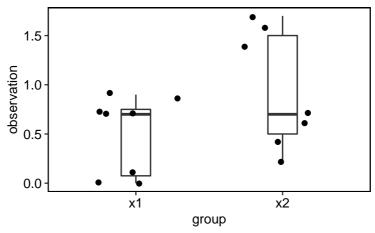


圖 4:獨立兩樣本的觀測值盒形圖。

5 多樣本單因子均值檢驗

5.1 常態且變方同質情況

檢驗以下三獨立樣本

之中央趨勢是否相等。

三樣本的描述性統計如表 1。由於三組樣本分布並不顯著偏離常態 (Shapiro-Wilk test, $p_1=0.709$, $p_2=0.85$, $p_3=0.925$),且變異數不顯著不等 (Bartlett test, $\chi^2=0.469$, DF = 2, p=0.791),故以 one-way ANOVA 檢驗 $H_0: \mu_1=\mu_2=\mu_3$ 。結果顯示,x 為顯著因子 (f=9.297, DF = (2,15), p=0.0024),且 η^2 顯示有 55.3% 的變異量可由 x 因子解釋。接下來以 Tukey's range test 進行多重比較,結果顯示, x_1 與 x_3 存在顯著差異,而 x_2 與另二組皆無顯著差異 (表 2; 圖 5)。

表 1: 獨立三樣本的描述性統計。

Group	Mean	SD	n
x_1	4.94	0.77	6
x_2	5.86	0.79	5
x_3	6.65	0.59	7

表 2: 獨立三樣本的事後多重比較。

Comparison	Estimate	95% CI lower	95% CI upper	$p_{ m adj}$
$x_2 - x_1$	0.917	-0.200	2.034	0.117
$x_{3} - x_{1}$	1.704	0.677	2.730	0.002
$x_{3} - x_{2}$	0.787	-0.293	1.867	0.175

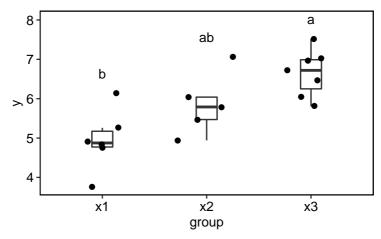


圖 5: 獨立三樣本的觀測值盒形圖。上方字母為多重比較的分群結果;若任二組存在相同字母則表示不存在顯著差異,反則反之。

5.2 常態且變方異質情況

檢驗以下三獨立樣本

之中央趨勢是否相等。

三樣本的描述性統計如表 3。由於三組樣本分布並不顯著偏離常態 (Shapiro-Wilk test, $p_1=0.158$, $p_2=0.593$, $p_3=0.388$),且變異數顯著不相等 (Bartlett test, $\chi^2=6.340$, DF = 2, p=0.042),故以 Welch one-way ANOVA 檢驗 $H_0: \mu_1=\mu_2=\mu_3$ 。結果顯示,x 為顯著因子 (f=8.248, DF = (2,8.953),p=0.009),且 η^2 顯示有 34.77% 的變異量可由 x 因子解釋。接下來以 Games-Howell method 進行多重比較,結果顯示, x_1 與 x_3 存在顯著差異,而 x_2 與另二組皆無顯著差異 (表 4;圖 6)。

表 3: 獨立三樣本的描述性統計。

Group	Mean	SD	n
x_1	4.073	0.906	6
x_2	6.596	1.267	5
x_3	6.989	2.803	7

表 4: 獨立三樣本的事後多重比較。

Comparison	Estimate	95% CI	t	DF	$p_{ m adj}$
$x_2 - x_1$	2.523	[0.536, 4.509]	3.727	7.103	0.017
$x_3 - x_1$	2.915	[-0.345, 6.175]	2.598	7.420	0.077
$x_{3} - x_{2}$	0.393	[-2.973, 3.758]	0.327	8.840	0.943

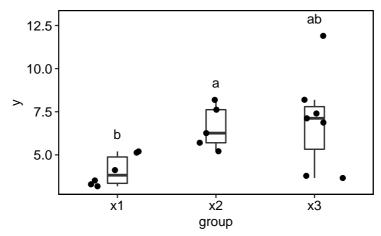


圖 6:獨立三樣本的觀測值盒形圖。上方字母為多重比較的分群結果;若任二組存在相同字母則表示不存在顯著差異,反則反之。

5.3 非常態情況

檢驗以下三獨立樣本

之中央趨勢是否相等。

三樣本的描述性統計如表 5。由於 x_1 與 x_3 分布顯著偏離常態 (Shapiro-Wilk test, $p_1=0.014$, $p_2=0.577$, $p_3=0.008$), 故以 Kruskal-Wallis rank sum test 檢驗 H_0 :中位數 $_1$ =中位數 $_2$ =中位數 $_3$ 。結果顯示, x 為顯著因子 ($\chi^2=9.041$, DF = 2, p=0.011), 且 $\eta^2=0.391$ 顯示高度效果量。Dunn's Kruskal-Wallis multiple comparisons 之多重比較結果顯示, x_1 與 x_3 存在顯著差異, 而 x_2 與另二組皆無顯著差異 (表 6; 圖 7)。

表 5: 獨立三樣本的描述性統計。

group	Mean	SD	n	
	x_1	5.225	5.617	8
	x_2	2.186	1.151	7
	x_3	0.733	0.644	6

表 6: Dunn's Kruskal-Wallis 多重比較之結果。

Comparison	z	$p_{\rm adj}$
$x_{1} - x_{2}$	0.964	0.335
$x_{1} - x_{3}$	2.979	0.009
$x_2 - x_3$	1.994	0.092

6 多樣本雙因子均值檢驗

(待撰)

7 簡單線性迴歸

以下樣本

x = 8.8 = 10.3 = 11.1 = 7.7 = 10.4 = 10.5 = 9.4 = 9.5y = 17 = 19.7 = 21.7 = 14.4 = 20 = 21.1 = 19.8 = 18.9

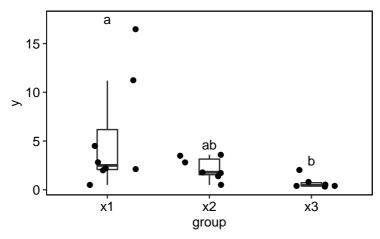


圖 7:獨立三樣本的觀測值盒形圖。上方字母為多重比較的分群結果;若任二組存在相同字母則表示不存在顯著差異,反則反之。

中, y 為應變數, x 為自變數, 建立 $y = \beta_0 + \beta_1 x + \varepsilon$ 的簡單線性迴歸。

簡單線性迴歸之結果如表 7 及圖 8a。結果顯示,每 x 增加 1 單位使 y 平均顯著增加 2.069 單位,應拒絕 $H_0:\beta_1=0$ (表 7a)。就效果量而言,自變數可解釋 $R^2=92.4\%$ 之變異量,屬高效果量。就迴歸診斷而言,殘差之 Q-Q圖 (圖 8b) 顯示殘差呈輕微右偏態,Shapiro-Wilk test 顯示殘差並未顯著偏離常態分布 ($W=0.848,\ p=0.090$),模型配適尚可。結論是,自變數顯著地增加應變數且效果明顯。

表 7: 簡單線性迴歸之結果。

Variable	Estimate \pm Std. Error	t (DF = 6)	p	95% CI
Intercept	-1.016 ± 2.408	-0.422	0.688	[-6.909, 4.877]
x	2.069 ± 0.247	8.389	< 0.001	[1.465, 2.672]

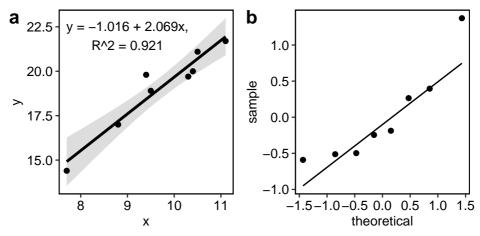


圖 8: 簡單線性迴歸之散布圖及迴歸線 (a) 及 Q-Q plot (b)。圖中灰色區域為 95% confidence pointwise band。

8 簡單相關

8.1 雙常態分布情況

以下樣本

$$x_1$$
 8.8 10.3 11.1 7.7 10.4 10.5 9.4 9.5 x_2 17 19.7 21.7 14.4 20 21.1 19.8 18.9

中,分析二變數之間的相關性。

首先以 Shapiro-Wilk multivariate normality test 檢驗 x_1 與 x_2 是否偏離雙變量常態分布,結果顯示不能拒絕 $H_0: x_1$ 與 x_2 之母體聯合分配為常態 $(W=0.860,\ p=0.120)$,故可計算 Pearson correlation。結果指出,r=0.960 屬高度正相關且應拒絕 $H_0: \rho=0$ (95% CI = [0.789,0.993],t=8.389, DF = 6,p<0.001;圖 9)。結論是, x_1 與 x_2 間存在顯著的高度正向線性相關性。

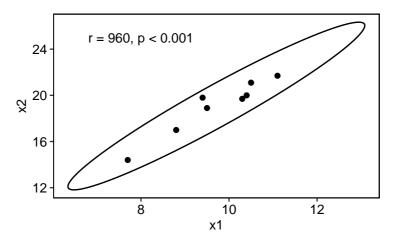


圖 9: x_1 與 x_2 散布圖。圖中楕圓區域表示相關性之 95% confidence ellipse。

8.2 次序相關

以下樣本

$$x_1$$
 7.5 5.4 5.9 6.1 7.9 7.9 6.6 6 x_2 0.3 0.2 4.4 2.7 0.1 1 0.3 0.5

中,分析二變數之間的相關性。

9 卡方適合度檢驗

隨機抽樣 40 人,發現各血型次數為 $\{O:A:B:AB\}=\{20:15:3:2\}$ 。檢驗 $H_0:\pi_O:\pi_A:\pi_B:\pi_{AB}=0.4:0.3:0.2:0.1$ 。

四種血型的母體比例估計如表 8。卡方適合度檢驗結果指出 $\chi^2=5.875$ (DF = 3)。由於血型 B 和 AB 之期望值極低 (< 1),故採用 4,999 次 permutation 得 p=0.112 而不能拒絕 H_0 。

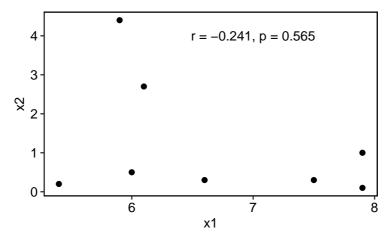


圖 10: x_1 與 x_2 散布圖。

表 8: 血型頻率與比例估計。

Blood type	Frequency	Proportion	95% CI
A	15	0.375	[0.216, 0.598]
AB	2	0.050	[0.008, 0.154]
В	3	0.075	[0.019, 0.194]
O	20	0.500	[0.312, 0.752]

10 卡方獨立性檢驗

隨機抽樣 332 人,發現居住地與收入分級的次數為

		income	
location	low	median	high
A	2	10	68
В	30	10	50
\mathbf{C}	60	19	101

試檢驗居住地與收入分級獨立 $H_0: \pi_{ij} = \pi_i \pi_j$ 。

居住地與收入的邊際比例如圖 11。卡方適合度檢驗結果指出應拒絕 H_0 表示居住地與收入並不獨立而存在關聯性 ($\chi^2=30.849$, DF = 4, p<0.001)。 Cohen's W = 0.297 顯示居住地與收入之關聯性幾乎達到中等程度 (0.3 即達

中度關聯)。若以居住地為多重比較的目標因子,再以卡方適合度比較居住地間比例並以 Holm-Bonferroni method 控制整體型一錯誤率,結果顯示居住地A顯著不同於居住地B及居住地C但B與C間無顯著差異(圖 11a)。綜合上述,居住地與收入並不獨立而存在顯著關聯性,主要由居住地A與另外二地點的差異(若以居住地為比較對象)造成。

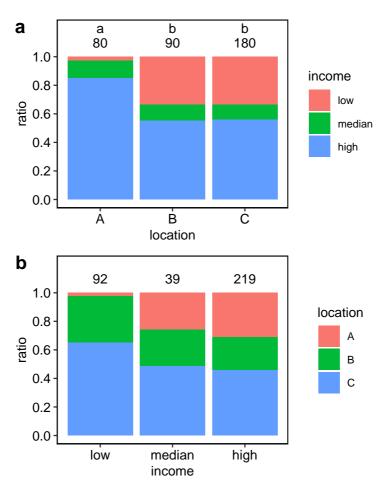


圖 11: 按居住地 (a) 與收入 (b) 的邊際比例。柱上方的數字表示該居住地或收入的樣本數。柱上方的小寫字母表示居住地間多重比較之結果;若任二組存在相同字母則表示不存在顯著差異,反則反之。

A R code

以下為本文中所有產生資料、進行分析、製作表格與繪圖之 R code, 亦可至 https://github.com/chenpanliao/report-statistical-results-TC/blob/master/plot/report-results.R 下載。

```
library(lsr)
 1
    library(coin)
 2
    library(ggpubr)
 3
    library(data.table)
    library(multcomp)
 5
    library(multcompView)
 6
    library(xtable)
7
    library(userfriendlyscience)
    library(mvnormtest)
     library(car)
10
     library(FSA)
11
     library(rstatix)
12
     library(rcompanion)
13
14
     ## normal one-sample test
15
     set.seed(1234)
16
     x <- rnorm(10, 10, 1) %>% round(1)
17
     paste0(x, collapse = ", ")
18
     mean(x)
19
     sd(x)
20
     shapiro.test(x)
21
     t.test(x)
22
     t.test(x, mu = 9)
23
     cohensD(x, mu = 9)
25
26
     ## non-normal one-sample test
27
     set.seed(1234)
28
     x <- rexp(10, 1) \% > \% round(2)
29
     paste0(x, collapse = ", ")
30
     mean(x)
31
     sd(x)
32
     shapiro.test(x)
33
     wilcox.test(x, mu = 2)
34
35
36
     ## normal paired test
37
     set.seed(1234)
38
    x1 <- rnorm(8, 10, 1) %>% round(1)
39
    x2 < - round(x1 + rnorm(8, 1), 1)
40
```

```
shapiro.test(x1 - x2)
41
     t.test(x1, x2, paired = T, mu = 0.1)
42
     paste0(x1, collapse = " & ")
43
     paste0(x2, collapse = " & ")
44
     mean(x1)
45
     sd(x1)
46
     mean(x2)
47
     sd(x2)
48
     mean(x1 - x2)
49
     sd(x1 - x2)
50
     cohensD(x1 - x2, mu = 0.5)
51
     d.plot <-
52
       data.table(
53
         observation = c(x1, x2),
54
         group = gl(2, 8, labels = c("x1", "x2")),
55
         block = gl(8, 1, 16)
       )
57
     f1 <-
58
       ggplot(d.plot, aes(group, observation)) +
59
       geom_boxplot(width = 0.2,
60
                     position = position_nudge(x = c(-0.2, 0.2)),
61
                     outlier.shape = NA) +
62
       geom_jitter(width = 0) +
63
       geom_segment(
64
         aes(
           x = 1,
66
           xend = 2.
67
           y = x1,
68
           vend = x2
69
70
         dcast(d.plot, block ~ group, value.var = "observation")
71
72
       theme_pubr(10, border = T)
73
     f2 <-
74
       dcast(d.plot, block ~ group, value.var = "observation") %>%
75
       .[, .(difference = x1 - x2), by = block] %>%
76
       ggplot(aes(x = 0, y = difference)) +
77
       geom_boxplot(width = 0.1) +
78
       geom_jitter(width = 0.05) +
79
       theme_pubr(10, border = T) +
80
       theme(
81
         axis.ticks.x = element_blank(),
         axis.text.x = element_blank(),
83
         axis.title.x = element_blank()
84
85
       vlab("difference\n(x1 - x2)") +
86
       xlim(c(-0.15, 0.15))
87
```

```
windows(4, 2.5)
88
      ggarrange(
89
        f1,
90
        f2,
91
        nrow = 1,
92
        labels = "auto",
93
        align = "h",
94
        widths = c(2, 1.2)
95
96
      ggsave("normal_paired_test.pdf")
97
98
99
      ## non-normal paired test
100
      set.seed(1212314)
101
      x1 \leftarrow runif(8, 5, 8) \%\% round(1)
102
     x2 \leftarrow round(x1 + runif(8, -1, 1), 1)
103
      shapiro.test(x1 - x2)
104
     wilcox.test(x1,
105
                   x2,
106
                   paired = T,
107
                   mu = 1,
108
                   exact = F)
109
      t.test(x1, x2, paired = T, mu = 0.1)
110
     paste0(x1, collapse = " & ")
111
     paste0(x2, collapse = " & ")
112
      mean(x1)
113
      sd(x1)
114
     mean(x2)
115
      sd(x2)
116
     mean(x1 - x2)
117
      sd(x1 - x2)
118
      cohensD(x1 - x2, mu = 0.5)
119
      table(x1 - x2 < 1)
120
      d.plot <-
121
        data.table(
122
          observation = c(x1, x2),
123
          group = gl(2, 8, labels = c("x1", "x2")),
124
          block = gl(8, 1, 16)
125
126
      f1 <-
127
        ggplot(d.plot, aes(group, observation)) +
128
        geom_boxplot(width = 0.2,
129
                      position = position_nudge(x = c(-0.2, 0.2)),
130
                      outlier.shape = NA) +
131
        geom_jitter(width = 0) +
132
        geom_segment(
133
          aes(
134
            x = 1,
135
            xend = 2,
136
```

```
y = `x1`,
yend = `x2`
137
138
          ),
139
          dcast(d.plot, block ~ group, value.var = "observation")
140
141
        theme_pubr(10, border = T)
142
      f2 <-
143
        dcast(d.plot, block ~ group, value.var = "observation") %>%
144
        [, (difference = x1 - x2), by = block] %%
        ggplot(aes(x = 0, y = difference)) +
146
        geom_boxplot(width = 0.1) +
147
        geom_jitter(width = 0.05) +
148
        theme_pubr(10, border = T) +
149
        theme(
150
          axis.ticks.x = element_blank(),
151
          axis.text.x = element_blank(),
152
          axis.title.x = element_blank()
153
154
        vlab("difference\n(x1 - x2)") +
155
        xlim(c(-0.15, 0.15))
156
      windows(4, 2.5)
157
      ggarrange(
158
        f1,
159
        f2,
160
        nrow = 1,
161
        labels = "auto".
162
        align = "h",
163
        widths = c(2, 1.2)
164
165
     ggsave("non-normal_paired_test.pdf")
166
167
168
     ## normal independent two-sample test
169
     set.seed(124)
170
     x1 <- rnorm(6, 10, 1) \% > \% round(1)
171
     x2 <- rnorm(7, 9, 1) \% > \% round(1)
      shapiro.test(x1)
173
      shapiro.test(x2)
174
      t.test(x1, x2)
175
     paste0(x1, collapse = " & ")
176
     paste0(x2, collapse = " & ")
177
     mean(x1)
178
      sd(x1)
179
     mean(x2)
180
      sd(x2)
181
     cohensD(x1, x2)
182
      d.plot <-
183
        data.table(
184
```

```
observation = c(x1, x2),
185
          group = c(rep("x1", 6), rep("x2", 7))
186
187
     windows(4, 2.5)
188
      ggplot(d.plot, aes(group, observation)) +
189
        geom_boxplot(width = 0.2,
190
                      outlier.shape = NA) +
191
        geom_jitter(width = 0.3) +
192
        theme_pubr(10, border = T)
193
      ggsave("normal_independent_test.pdf")
194
195
196
     ## non-normal independent two-sample test
197
     set.seed(6324)
198
     x1 <- runif(8, 0, 1) \% > \% round(1)
199
     x2 <- runif(7, 0, 2) %>% round(1)
200
     shapiro.test(x1)
201
     shapiro.test(x2)
202
     paste0(x1, collapse = " & ")
203
     paste0(x2, collapse = " & ")
204
     mean(x1)
205
     sd(x1)
206
     mean(x2)
207
     sd(x2)
208
     windows(4, 2.5)
209
     d.plot <-
210
        data.table(
211
          observation = c(x1, x2),
          group = c(rep("x1", 8), rep("x2", 7))
213
214
     windows(4, 2.5)
215
      ggplot(d.plot, aes(group, observation)) +
216
        geom_boxplot(width = 0.2,
217
                      outlier.shape = NA) +
218
        geom_jitter(width = 0.3) +
219
        theme_pubr(10, border = T)
220
     ggsave("non-normal_independent_test.pdf")
221
222
223
     ## oneway ANOVA
224
     set.seed(364)
225
        data.table(y = round(c(rep(5, 6), rep(6, 5), rep(7, 7)) + rnorm(18), 2),
227
                   group = factor(c(rep("x1", 6), rep("x2", 5), rep("x3", 7))))
228
     tapply(d$y, d$group, shapiro.test)
229
     bartlett.test(y ~ group, d)
230
     d[, paste0(y, collapse = " & "), by = group]
231
     d[, .(Mean = mean(y),
232
```

```
SD = sd(y),
233
            n = length(y)), by = group] %>%
234
       as.data.frame %>%
235
       xtable(
236
237
          digits = 3,
238
          auto = T,
230
          label = "table:oneway_ANOVA".
240
          caption = "獨立三樣本的描述性統計。"
241
       )
242
     fit <- aov(y ~ group, d)
243
      summary(fit)
244
      TukeyHSD(fit, "group")$group
245
     TukeyHSD(fit, "group")$group %>%
246
       xtable(
247
          digits = 3,
248
          auto = T,
249
          label = "table:oneway_ANOVA_post".
250
          caption = "獨立三樣本的事後多重比較。"
251
252
      fit.mult <-
253
        TukeyHSD(fit, "group")$group[, "p adj"] %>%
254
       multcompLetters %>%
255
        .$Letters %>%
256
       data.table(group = names(.), rank = .) %>%
257
       merge(., d[, .(max.val = max(y)), by = group], by = "group")
258
      windows(4, 2.5)
259
      ggplot(d, aes(group, y)) +
260
       geom_boxplot(width = 0.2,
261
                     outlier.shape = NA) +
262
       geom_jitter(width = 0.3) +
263
       geom_text(aes(group, max.val + 0.5, label = rank),
264
                  fit.mult,
265
                  size = 10 * 0.352777778) +
266
        theme_pubr(10, border = T)
267
      ggsave("oneway_ANOVA.pdf")
268
269
270
     ## Welch's ANOVA
271
     set.seed(12234)
272
     d <-
273
       data.table(y = round(rnorm(
275
         mean = c(rep(4, 6), rep(6, 5), rep(7, 7)),
276
         sd = c(rep(1, 6), rep(2, 5), rep(3, 7))
277
       group = factor(c(rep("x1", 6), rep("x2", 5), rep("x3", 7)))
279
      tapply(d$y, d$group, shapiro.test)
280
     bartlett.test(y ~ group, d)
281
```

```
d[, paste0(y, collapse = " & "), by = group]
282
     d[, .(Mean = mean(y),
283
            SD = sd(y),
284
            n = length(y)), by = group] %>%
285
       as.data.frame %>%
286
       xtable(
287
          digits = 3,
289
          auto = T
290
          label = "table:Welch_ANOVA"
291
          caption = "獨立三樣本的描述性統計。"
292
203
     aov(y ~ group, data = d) %>% summary
294
     oneway.test(y ~ group, data = d)
295
     mc <- posthocTGH(d$y, d$group, digits = 3)$output$games.howell</pre>
296
     mc %>%
297
       xtable(
298
          digits = 3,
299
          auto = T,
300
          label = "table:Welch_ANOVA_post"
301
          caption = "獨立三樣本的事後多重比較。"
302
303
      fit.mult <-
304
       mc$p %>%
305
       set_names(rownames(mc)) %>%
306
       multcompLetters %>%
307
        .$Letters %>%
308
       data.table(group = names(.), rank = .) %>%
309
       merge(., d[, .(max.val = max(y)), by = group], by = "group")
310
     windows(4, 2.5)
     ggplot(d, aes(group, y)) +
312
       geom_boxplot(width = 0.2,
313
                     outlier.shape = NA) +
314
       geom_jitter(width = 0.3) +
315
       geom_text(aes(group, max.val + 1, label = rank),
316
                  fit.mult,
317
                  size = 10 * 0.352777778) +
318
       theme_pubr(10, border = T)
      ggsave("Welch_ANOVA.pdf")
320
321
322
      ## Kruskal-Wallis Rank Sum Test
323
     set.seed(1132234)
324
     d <-
325
       data.table(y = c(rexp(8, 0.2), rexp(7, 0.5), rexp(6, 1)) %>% round(1),
326
                   group = c(rep("x1", 8), rep("x2", 7), rep("x3", 6)))
327
     d[, shapiro.test(y), by = group]
328
     d[, pasteO(y, collapse = " & "), by = group]
329
     d[, .(Mean = mean(y),
330
```

```
SD = sd(y),
331
            n = length(y)), by = group] %>%
332
       as.data.frame %>%
333
       xtable(
334
335
          digits = 3,
336
          auto = T,
337
          label = "table:rank_oneway"
338
          caption = "獨立三樣本的描述性統計。"
339
       )
340
     kruskal.test(y ~ group, d)
341
     kruskal_effsize(d, y ~ group)
342
      dunnTest(y ~ group, d)
343
      dunnTest(y ~ group, d)$res %>%
344
       xtable(caption = "Dunn's Kruskal-Wallis多重比較之結果。",
345
               label = "table:rank_oneway_post",
346
               digits = 3)
347
      fit.mult <-
348
       dunnTest(y ~ group, d)$res[, "P.adj"] %>%
349
       set_names(dunnTest(y ~ group, d)$res[, "Comparison"] %>% gsub(" ", "", .)) %>%
350
       multcompLetters %>%
351
        .$Letters %>%
352
       data.table(group = names(.), rank = .) %>%
353
       merge(., d[, .(max.val = max(y)), by = group], by = "group")
354
     windows(4, 2.5)
355
      ggplot(d, aes(group, y)) +
356
       geom_boxplot(width = 0.2,
357
                     outlier.shape = NA) +
358
       geom_jitter(width = 0.3) +
359
       geom_text(aes(group, max.val + 1, label = rank),
360
361
                  fit.mult,
                  size = 10 * 0.352777778) +
362
       theme_pubr(10, border = T)
363
      ggsave("rank_oneway.pdf")
364
365
366
     ## simple linear regression
367
     set.seed(1234)
368
     x <- rnorm(8, 10) \% > \% round(1)
369
     y < -(x * 2 + rnorm(8)) %>% round(1)
370
     d <- data.table(x, y)</pre>
371
     fit <-lm(y \sim x, d)
372
     summary(fit)
373
     confint(fit)
374
     shapiro.test(fit$residuals)
375
     d[, paste0(x, collapse = " & ")]
376
     d[, paste0(y, collapse = " & ")]
377
     fit %>% {
378
       cbind(
379
```

```
(.) %>% summary %>% .$coefficients ,
380
          confint(.)
381
        )
382
      } %>%
383
        xtable(caption = "簡單線性迴歸之結果。"
384
               label = "table:simple_regression",
385
               digits = 3)
386
      f1 <-
387
        ggplot(d, aes(x, y)) +
388
        geom_smooth(method = "lm", color = 1, fill = "#aaaaaa") +
389
        geom_point() +
390
        annotate(
391
          "text"
392
          label = "y = -1.016 + 2.069x, \nR^2 = 0.921",
393
          x = 9,
394
          y = 22,
395
          size = 10 * 0.352777778
396
397
        theme_pubr(10, border = T)
398
      f2 <-
399
        ggplot(d, aes(sample = fit$residuals)) +
400
        stat_qq() +
401
        stat_qq_line() +
402
        theme_pubr(10, border = T)
403
      windows(5, 2.5)
404
      ggarrange(
405
        f1,
406
        f2,
407
        nrow = 1,
408
        labels = "auto",
409
        align = "hv",
410
        widths = c(1, 1)
411
412
     ggsave("simple_regression.pdf")
413
414
415
     ## simple linear cor
416
     set.seed(1234)
417
     x1 <- rnorm(8, 10) %>% round(1)
418
     x2 <- (x1 * 2 + rnorm(8)) %>% round(1)
419
      d <- data.table(x1, x2)</pre>
420
     d[, paste0(x1, collapse = " & ")]
421
      d[, paste0(x2, collapse = " & ")]
422
     mshapiro.test(d %>% as.matrix %>% t)
423
     cor.test(d$x1, d$x2)
424
      fit <- lm(x2 ~ x1, d)
425
      windows(4, 2.5)
426
     ggplot(d, aes(x1, x2)) +
427
        geom_path(data =
428
```

```
dataEllipse(
429
                       x1,
430
                       x2,
431
                        draw = F,
432
                        levels = 0.95,
433
                        segments = 500
434
                     ) %>%
435
                     as.data.table,
436
                   aes(x, y)) +
437
        geom_point() +
438
        annotate(
439
          "text"
440
          label = "r = 960, p < 0.001",
441
          x = 8.
442
          y = 25,
443
          size = 10 * 0.352777778
444
445
        theme_pubr(10, border = T)
446
      ggsave("simple_cor.pdf")
447
448
449
      ## spearman correlation
450
      set.seed(125)
451
     x1 <- runif(8, 5, 8) \% > \% round(1)
452
     x2 <- rexp(8) \% > \% round(1)
453
      d <- data.table(x1, x2)</pre>
454
     mshapiro.test(d %>% as.matrix %>% t)
455
     d[, paste0(x1, collapse = " & ")]
456
      d[, paste0(x2, collapse = " & ")]
457
      cor.test(d$x1, d$x2, method = "spearman")
458
      windows(4, 2.5)
459
      ggplot(d, aes(x1, x2)) +
460
        geom_point() +
461
        annotate(
462
          "text",
463
          label = "r = -0.241, p = 0.565",
464
          x = 7
465
          y = 4,
466
          size = 10 * 0.352777778
467
468
        theme_pubr(10, border = T)
469
      ggsave("spearman_cor.pdf")
470
471
472
      ## chi-squared goodness of fit
473
      obs.val \leftarrow c(20, 15, 3, 2)
474
      exp.p <- c(4, 3, 2, 1) %>% divide_by(sum(.))
475
476
        data.table(observation = obs.val,
477
                    expectation = exp.p * sum(obs.val),
478
```

```
blood = c("0", "A", "B", "AB")) %>%
479
       melt(measure.vars = c("observation", "expectation"), value.name = "frequency") %>%
480
        .[, proportion := frequency / sum(frequency), by = variable] %T>%
481
       print
482
      glm(
483
       frequency ~
484
          -1 + blood +
485
          offset(sum(d[variable == "observation"]$frequency) %>% log %>% rep(4)),
486
       family = poisson,
487
       data = d[variable == "observation"]
488
      ) %>%
489
       confint %>%
490
       exp %>%
491
       as.data.table(keep.rownames = "blood") %>%
492
        .[, blood := gsub("blood", "", blood)] %>%
493
       merge(d[variable == "observation"], .) %>%
494
        .[, variable := NULL] %>%
495
       xtable(caption = "血型頻率與比例估計。",
496
               label = "table:chisq_goodness",
497
               digits = 3)
498
     chisq.test(
499
       obs.val,
500
       p = exp.p,
501
        rescale.p = T,
502
       simulate.p.value = T,
503
       B = 4999
504
     )
505
506
507
     ## chi-squared independent test
508
     d <-
509
       matrix(c(2, 10, 68, 30, 10, 50, 60, 19, 101), 3, byrow = T) %>%
       set_rownames(c("A", "B", "C")) %>%
511
       set_colnames(c("low", "median", "high"))
512
     chisa.test(d)
513
     chisq.test(d, simulate.p.value = T, B = 4999)
514
     # ufs::cramersV(d)
515
     # ufs::confIntV(d)
516
     # rcompanion::cramerV(d, ci = T, bias.correct = T)
517
     chisq.val <- chisq.test(d)$statistic</pre>
518
     C <- sgrt(chisq.val/(chisq.val + sum(d)))
519
     W <- sqrt(C^2 / (1-C^2))
520
     W # Cohan's W
521
522
       combn(1:nrow(d), 2, function(x) {
523
          chisq.test(d[, c(x[1], x[2])], simulate.p.value = T, B = 4999)
524
        }) %>%
525
        .[c(1, 3), ] %>%
526
       as.matrix %>%
527
```

```
set_rownames(c("chisq", "p")) %>%
528
        set_colnames(combn(rownames(d), 2, function(x) {
529
          paste0(x[1], "-", x[2])
530
        })) %T>%
531
        print %>%
532
        .["p",] %>%
533
        unlist %>%
534
        p.adjust %>%
535
        multcompLetters %>%
536
        .$Letters %T>%
537
        print
538
      d %>% as.table %>% prop.table
539
      d %>% as.table %>% plot
540
      d.long <-
541
        merge(
542
          d %>%
543
            reshape2::melt(
544
              varnames = c("location", "income"),
545
              value.name = "frequency"
546
            ) %>%
547
            as.data.table,
548
          d %>% as.table %>% prop.table(margin = 1) %>%
549
            reshape2::melt(
550
              varnames = c("location", "income"),
551
              value.name = "ratio by location"
552
            ) %>%
553
            as.data.table,
554
          by = c("location", "income")
555
        ) %>%
556
        merge(
557
              d %>% as.table %>% prop.table(margin = 2) %>%
558
            reshape2::melt(
559
              varnames = c("location", "income"),
560
              value.name = "ratio by income"
561
            ) %>%
562
            as.data.table
563
        ) %T>%
564
        print
565
      f1 <-
566
        ggplot(d.long, aes(location, `ratio by location`)) +
567
        geom_col(aes(fill = income)) +
568
        theme_pubr(10, border = T) +
569
        annotate(
570
          "text",
571
          label = rowSums(d),
572
          x = 1:3,
          y = 1.1,
574
          size = 10 * 0.352777778
575
576
```

```
annotate(
577
          "text",
578
          label = mc,
579
          x = 1:3,
580
          y = 1.2,
581
          size = 10 * 0.352777778
582
        ) +
583
        scale_y_continuous("ratio", breaks = seq(0, 1, 0.2), limits = c(0, 1.2))
584
      f2 <-
585
        ggplot(d.long, aes(income, `ratio by income`)) +
586
        geom_col(aes(fill = location)) +
587
        theme_pubr(10, border = T) +
588
        annotate(
589
          "text",
590
          label = colSums(d),
591
          x = 1:3,
592
          y = 1.1,
593
          size = 10 * 0.352777778
594
595
        scale_y = continuous("ratio", breaks = seq(0, 1, 0.2), limits = c(0, 1.2))
596
     windows(4, 5)
597
      ggarrange(f1, f2, nrow = 2, align = "hv", labels = "auto", legend = "right")
598
     ggsave("chisq_independent.pdf")
599
```